




Overview

1/ Các bước xây dựng mô hình ML:

- 1. Thu thập dữ liệu, phân tích và chọn lựa các features
- 2. Chia tập dữ liệu thành các tập cho training và testing (hoặc validation)
- 3. Lựa chọn mô hình
- 4. Tiến hành huấn luyện mô hình với tập train
- 5. Kiểm chứng lại mô hình với tập test/validation

2/ Hai loại bài toán chính trong ML:



Học có giám sát (Supervised Learning)	Học không giám sát (Unsupervised learning)
Ví dụ: Phương pháp này giống như học với một người thầy đã cho sẵn đáp án. • Dữ liệu đầu vào (Input data): Cung cấp hình ảnh các quả táo. • Nhãn đính kèm (Annotations): Chỉ rõ cho mô hình biết “Đây là những quả táo”. • Quá trình học (Model): Mô hình ghi nhớ đặc điểm quả táo dựa trên nhãn được cung cấp. • Kết quả dự đoán (Prediction): Khi đưa một quả táo mới (có dấu chấm hỏi), mô hình tự tin nhận diện chính xác “Nó là một quả táo!”.	Phương pháp này là mô hình phải tự mày mò nghiên cứu mà không có ai hướng dẫn. • Dữ liệu đầu vào (Input data): Cung cấp một tập hợp lộn xộn nhiều loại trái cây (táo đỏ, táo xanh/bóng, chuối) và không có nhãn giải thích. • Quá trình học (Model): Mô hình tự phân tích các đặc điểm ngoại hình như hình dáng, màu sắc, kích thước. • Kết quả đầu ra: Mô hình tự động phân tách dữ liệu thành 3 nhóm riêng biệt (nhóm táo đỏ, nhóm quả màu hồng/cam, nhóm quả chuối) dựa trên sự tương đồng, dù không biết tên gọi cụ thể của từng loại.
Định nghĩa: Là phương pháp ML sử dụng dữ liệu đã được giám sát Classification  Supervised learning	Là các phương pháp ML dùng để phân tích và phân cụm dữ liệu không được gán nhãn Clustering  Unsupervised learning
Sự khác biệt: Labeled Data (dữ liệu đầu <u>đã được</u> gán nhãn)	<u>Un</u>labeled Data (dữ liệu đầu vào <u>không được</u> gán nhãn)

3/ Overfitting vs Underfitting


Khi xây dựng ML models:

- Tập train (training set): để model dựa vào mà thay đổi các hệ số (**hay hiểu là mình fix mô hình vào dữ liệu**)
- Tập test (test set): để kiểm chứng lại với dữ liệu mà model chưa nhìn thấy



→ mục tiêu: tổng quát hoá được mối quan hệ (generalization), nhằm đạt được **độ chính xác cao trên cả hai tập**

* Tuy nhiên trong thực tế gặp phải 1 số vấn đề như:



- **Underfitting**: tìm ra đường thẳng để tìm được mối tương quan giữa x và y, mối quan hệ tuyến tính. Sai số rất lớn giữa các điểm màu cam với đường xanh rất xa, có 1 vài điểm thì trùng đường xanh, nhưng 1 số điểm khác lại rất xa → khi tính MSE thì rất lớn → dẫn đến độ chính xác không tốt cả trên tập train.
- **Overfitting**: có đường màu xanh dường như rất đúng với dữ liệu → **sai số** mà đường này thể hiện rất là **nhỏ**, nhược điểm nếu có dữ liệu mới chưa training trong tập train → mô hình thể hiện không đúng, trường hợp này sai số rất lớn
- **Balanced**: có 1 mô hình, mà đường như sai số tương đối nhỏ và nó phù hợp với tập test và tập train


Định nghĩa underfitting và overfitting:

- Underfitting (chưa khớp): là tình trạng mô hình có độ chính xác thấp với cả tập train và tập test
- Overfitting (quá khớp): là tình trạng mô hình cho độ chính xác cao với tập train, nhưng lại kém với tập test (*** phổ biến hơn Underfitting**)


→ Underfitting dễ xử lý hơn Overfitting

Hai vấn đề lớn với mô hình ML

- High **bias**: lỗi trên cả tập train và test đều cao
- High **variance**: lỗi trên tập train thấp, trên tập test cao
→ Mô hình quá đơn giản hay bị High bias (cao cả trên test và sample)
Mô hình phức tạp hay bị high variance



* Ví dụ thêm về Underfit và Overfit



Underfit (high bias): ví dụ ở đây dùng đường thẳng để phân loại, chúng ta muốn thay đổi đường thẳng đó lên hoặc xuống thì cũng không thể nào kết loại phân loại tốt → vì dữ liệu đan xen vào nhau và mô hình mình quá đơn giản chỉ với 1 đường thẳng

→ high training error: sai số trên tập train

→ high test error: thử qua tập test thì sai số trên tập test cũng cao

Overfitting (high variance): có đường uốn lượn rất nhiều, tức mô hình mình phức tạp hơn, tham số nhiều hơn. Như vậy tập train data gần như đã phân loại rồi đúng 100% trong ví dụ này. Cái này đúng trên train nhưng bên test có thể sai số rất lớn.

→ low training error: tức là tập train sai số rất nhỏ

→ high test error: tập test có thể sai số rất cao

Optimum: ta có mô hình độ phức tạp vừa phải → tốt hơn, nhìn hình thấy mặc dù tập train vẫn có sai số, có những điểm nằm sai nhóm, tuy nhiên là nó sẽ tốt hơn cho tập test

→ Low training error

→ Low test error

Khái niệm Bias và Variance

- **Bias** là sự sai khác giữa trung bình dự đoán của mô hình chúng ta xây dựng với giá trị chính xác đang cố gắng để dự đoán. Một mô hình với trị số bias cao đồng nghĩa với việc mô hình đó không quan tâm nhiều tới dữ liệu huấn luyện, khiến cho mô hình trở nên đơn giản quá. Nó thường dẫn đến việc mô hình có mức độ lỗi cao cả trên tập huấn luyện và tập kiểm thử.

Phạm Thị Xuân Hiền

- **Variance** đặc trưng cho mức độ tản mát của giá trị dự đoán cho điểm dữ liệu. Mô hình với mức độ variance cao tập trung chú ý nhiều vào dữ liệu huấn luyện và không mang được tính tổng quát trên dữ liệu chưa gặp bao giờ. Từ đó dẫn đến mô hình đạt được kết quả cực kì tốt trên tập dữ liệu huấn luyện, tuy nhiên kết quả rất tệ với tập dữ liệu kiểm thử.

--- để dễ hiểu hơn, tôi ví dụ qua việc bắn súng vào hồng tâm

Bias (độ chệch): là độ lệch của các phát súng so với hồng tâm

- Bias cao nghĩa là mô hình **quá đơn giản**, bắn toàn trượt mục tiêu. Nó lười học, không thêm hiểu sâu dữ liệu nên làm sai trên cả tập training lẫn tập test

Variance (phương sai): là độ phân tán giữa các phát bắn với nhau

- Variance cao nghĩa là mô hình quá phức tạp. Khi đi tập bắn thì trúng 100%, nhưng khi đi thi là bắn sai/ lung tung, kết quả rất tệ → Overfitting (quá khớp)



Tham khảo tại: <https://viblo.asia/p/the-bias-variance-decomposition-eW65Gm3YZDO>

Tổng kết:

- Overfitting gây ra bởi:
 - Mô hình quá phức tạp so với cần thiết
 - Không tổng quát hoá được tốt khi gặp dữ liệu chưa bao giờ thấy → việc tổng quát hoá kém
 - Thường do mô hình “nhầm” thành phần nhiễu là thành phần quan trọng
- Một số phương pháp phổ biến để tránh overfitting
 - Tăng thêm dữ liệu (nếu quá ít): thu thập thêm hoặc dùng data augmentation
 - Phương pháp lấy lại mẫu (re-sampling): chia thành k tập con và thực hiện k-cross validation
 - Dùng các phương pháp regularization
 - Các phương pháp nâng cao trong Deep Learning


Linear Regression

- Hồi quy tuyến tính là giải thuật dự đoán giá trị của dữ liệu dựa vào sự tương quan tuyến tính
- Hàm $y = ax + b$




Các hạn chế:

- Không bao giờ tìm được “perfect fit” luôn luôn có sai số
- Khả năng dự đoán “**tương đối tốt**” với **dữ liệu đã có**
- Không giải thích được (tương tự) cách thức các biến tương tác với nhau → * xảy ra với hầu hết bài toán ML không riêng hồi quy tuyến tính



- Nếu có **quá nhiều features** và test score kém
→ bị overfitting
→ lý do chính: **model** trở nên **quá phức tạp**



Công thức tính hàm loss:

$$\sum_{i=1}^M (y_i - \hat{y}_i)^2 = \sum_{i=1}^M \left(y_i - \sum_{j=0}^p w_j \times x_{ij} \right)^2$$


Để giải quyết các vấn đề này dùng kỹ thuật **Regularization**

Số lượng features đầu vào rất lớn nhưng 1 số features thật sự không đóng vai trò gì cho output, tuy nhiên do yếu tố nhiễu, quá trình training vẫn đưa ra được các giá trị $\neq 0$ nào đó → dẫn đến vấn đề overfitting

Kỹ thuật regularization giúp chúng ta hạn chế những features không quan trọng gây nhiễu, bằng cách những hệ số giả sử như $w_0, w_1, \dots$ đưa về 0.

Regularization (chính quy hoá, chuẩn hoá, thể thức hoá) là gì?


- Làm cho mô hình ít phức tạp hơn
- Các kỹ thuật cơ bản:
 - Early stopping:
 - Thêm thành phần vào hàm mất mát
 - Dropout (sử dụng bởi neural network trong Deep Learning)



Early stopping: sử dụng tập validation cho “kết thúc sớm”

Thay vì chia dataset thành 2 tập, thì chia làm 3 tập


- Train set: mô hình học và tự thay đổi hệ số
- Validation set: để chúng ta xác định thời điểm dừng training lại
- Test set: kiểm tra đánh giá chất lượng mô hình



Giai đoạn đầu mô hình đang học : sai số giảm cả trên 3 tập

Đến thời điểm nào đó trên tập validation nó không đc cải thiện nữa, nếu vẫn tiếp tục training nó sẽ dẫn đến sai số cho tập test → mình sẽ dừng tại đó.

Dropout với neural network: trong quá trình train, có thể bỏ bớt 1 số tham số trong mô hình



Nâng cao:

Các giải thuật regularization cho bài toán regression:

- Ridge Regression
- Least Absolute Shrinkage and Selection Operator (LASSO)
- Elastic Net Regression
- Least-Angle Regression (LARS)

Xem code tại: [demo1-Regression.ipynb](#)